

## Podsumowanie prac na temat predykcji poziomu zanieczyszczeń

Publikacja	Dane	Zastosowane metody i ich parametry	Rezultaty	Narzędzia	Uwagi		
SIWEK, Krzysztof; OSOWSKI, Stanisław. Data mining methods for prediction of air pollution. <i>International Journal of Applied Mathematics and Computer Science</i> , 2016, 26.2: 467-478.	<p>Dane zebrane z 2 stacji meteorologicznych w Warszawie w latach 2001-2014. Eksperymenty przeprowadzone dla zanieczyszczeń: PM10, SO2, NO2, O3.</p> <p>Wybrane parametry wejściowe dla PM10 (jeśli nie wskazano inaczej chodzi o dane z ostatnich 24 godzin):</p> <ul style="list-style-type: none"><li>• min., maks i średnie zanieczyszczenie;</li><li>• min., maks. I średnia temperatura;</li><li>• maks. Wilgotność;</li><li>• średnie nasłonecznienie;</li><li>• min., maks. I średnia prędkość wiatry wzdłuż współrzędnej x/y;</li><li>• poziom zanieczyszczenia kolejnego dnia przewidziany przez trend liniowy;</li><li>• wilgotność przewidziana na kolejny dzień przez trend liniowy;</li><li>• poziom zanieczyszczenia zmierzony kilka razy w ciągu doby – nie wykorzystano wszystkich 24 pomiarów;</li><li>• binarna reprezentacja pory roku;</li><li>• kod typu dnia – roboczy lub weekend.</li></ul> <p>Wymieniono tu parametry wybrane przez algorytm genetyczny lub regresję krokową dla PM10. Dla pozostałych zanieczyszczeń zbiór uzyskanych parametrów jest inny. Dodatkowo parametry znalezione z użyciem algorytmu genetycznego nie muszą się pokrywać z tymi znanymi przez regresję krokową (forward selection).</p>	<p>Praca zawiera wyniki eksperymentów z użyciem:</p> <ul style="list-style-type: none"><li>• Random Forest Decision Tree</li><li>• Multi-layer perceptron - 12 neuronów w warstwie ukrytej;</li><li>• Radial basis function - 300 gaussowskich funkcji bazowych z <math>\sigma=1</math>;</li><li>• Support Vector Machine with Gaussian kernel – C=100, <math>\epsilon=0.01</math>, <math>\sigma=1</math> .</li></ul> <p>Przetestowano również skuteczność systemu złożonego z połączonych sieci MLP, RBF, SVR, gdzie wartości wyjściowe były przekazywane na wejście drzewa RF (RF-fusion) lub ich średnia ważona była używana do przewidzenia poziomu zanieczyszczenia n-dni do przodu (w_avg).</p>	Wyniki dla PM10 i wyboru parametrów algorytmem genetycznym.	MATLAB – użyty do weryfikacji wyników w porównaniu do modelu liniowego ARX. Brak informacji o narzędziach użytych do implementacji samych metod.	Artykuł potencjalnie przydatny do podjęcia decyzji odnośnie danych wejściowych modelu.		
						MAPE	MAE
			RF			17.92	5.405
			MLP			23.36	7.269
			RBF			23.36	7.269
			SVR			23.36	7.269
w_avg	22.68	6.979					

<p>LOYA, Nahun, et al. Forecast of air quality based on ozone by decision trees and neural networks. In: <i>Mexican International Conference on Artificial Intelligence</i>. Springer, Berlin, Heidelberg, 2012. p. 97-106.</p>	<p>Dane pochodzą z 3 stacji meteorologicznych na terenie Mexico City. Pomiary były wykonywane co godzinę w okresie między 2010 – 2011 r. Zanieczyszczenia: O<sub>3</sub>, CO, NO<sub>2</sub>. Parametry brane pod uwagę:</p> <ul style="list-style-type: none"> <li>• godzina,</li> <li>• temperatura,</li> <li>• wilgotność względna,</li> <li>• prędkość i kierunek wiatru.</li> </ul> <p>Zależności między parametrami a zanieczyszczeniem oszacowano na podstawie testu chi-kwadrat. Poziomy zanieczyszczeń zostały zdyskretyzowane.</p> <p>Brakujące dane są interpolowane przez średnią wartość sąsiednich pomiarów <math>s(t-1)</math>, <math>s(t+2)</math>.</p>	<p>Cel predykcji: poziom zanieczyszczenia (wyrażony w postaci zdyskretyzowanej) w chwili <math>t + 1</math> godzina lub <math>t + 8</math> godzin (?).</p> <p>Multi Layer Perceptron najlepsze rezultaty dla 1 warstwy ukrytej z 8 lub 9 neuronami (w zależności od stacji meteo)</p> <p>C4.5 decision tree: factor = 0.05, MinNumObj = 2 , Unpruned = F ALSE.</p> <p>Random Forest: MaxDepth = 10, Debug = F else, NumTrees = 50, Seed = 1;</p>	<p>Drzewa decyzyjne okazały się najskuteczniejsze. Najlepsze rezultaty uzyskano dla drzew typu Random Forest. Skuteczność była mierzona na podstawie sukcesu klasyfikacji.</p> <p>Zaproponowano dokonywanie klasyfikacji na danych podzielonych na okresy 8-godzinne. Pozwoliło to na zredukowanie błędów w okresach wzmożonego uwalniania zanieczyszczeń do atmosfery obserwowanych w godzinach 12:00 – 20:00. Skuteczność predykcji sięgnęła wówczas &gt; 80% w godzinach 9:00 – 17:00 i &gt; 90 % w godzinach 1:00 – 8:00 i 18:00 – 24:00.</p>	Weka	
<p>Subramanian, V. N. (2016). Data analysis for predicting air pollutant concentration in Smart city Uppsala (Dissertation). Retrieved from <a href="http://urn.kb.se/resolve?urn=urn:nbn:se:uu:diva-283405">http://urn.kb.se/resolve?urn=urn:nbn:se:uu:diva-283405</a></p>	<p>Dane pochodzące ze stacji monitorującej w Uppsali. Rodzaje zanieczyszczeń: PM<sub>2.5</sub>, PM<sub>10</sub>, NO, NO<sub>2</sub>. Parametry:</p> <ul style="list-style-type: none"> <li>• natężenie ruchu drogowego (szacowana liczba samochodów).</li> <li>• dzień tygodnia,</li> <li>• godzina,</li> <li>• temperatura,</li> <li>• prędkość i kierunek wiatru,</li> <li>• wilgotność,</li> <li>• opad deszczu,</li> <li>• nasłonecznienie,</li> <li>• poziom zanieczyszczenia 1 i 2 godziny wcześniej.</li> </ul> <p>Dane zostały znormalizowane.</p>	<p>Cel predykcji: poziom zanieczyszczenia w chwili <math>t + 1</math> godz.</p> <p>Sieć neuronowa z jedną warstwą ukrytą z 9 neuronami. Parametry algorytmu uczenia:</p> <ul style="list-style-type: none"> <li>• learning rate = 0.3;</li> <li>• momentum = 0.2.</li> </ul> <p>Regresja liniowa wielokrotna (MLR).</p>	<p>Skuteczność sieci neuronowej wyższa niż MLR, ale na porównywalnym poziomie: błąd względny: 37.23% w porównaniu do 40.64%.</p>	Nie wskazano	W pracy pokazano, że możliwe jest wykorzystanie modelu nauczonego na podstawie danych na temat jednego rodzaju zanieczyszczenia PM <sub>2.5</sub> do predykcji innego rodzaju zanieczyszczenia – PM <sub>10</sub> , NO, NO <sub>3</sub> .
<p>Memarianfard, M., Hatami, A.,</p>	<p>Dane zgromadzone w latach 2011 – 2015 przez 19 stacji monitorowania jakości powietrza w</p>	<p>Sieć neuronowa z jedną warstwą ukrytą o 6 neuronach i jednym neuronem</p>	<p>Współczynnik korelacji R dla zbioru danych:</p>	Nie wskazano	Zdaje się, że w pracy nie

Memarianfard, M. (2017). 'Artificial neural network forecast application for fine particulate matter concentration using meteorological data	Teheranie.  Parametry: <ul style="list-style-type: none"> <li>• SO2</li> <li>• NO2</li> <li>• CO</li> <li>• wilgotność</li> <li>• prędkość wiatru</li> <li>• temperatura</li> </ul>	wyjściowym. Sieć była trenowana przez 113 epok.	<ul style="list-style-type: none"> <li>• treningowych = 0.65898,</li> <li>• walidacyjnych = 0.6419,</li> <li>• testowych = 0.54027,</li> <li>• całego = 0.62331</li> </ul>		wytlumaczono, co dokładnie i z jakim wyprzedzeniem ma być predykowane (np. czy za godzinę dojdzie do przekroczenia dopuszczalnego zanieczyszczenia powietrza
Hoshyaripour, Gholamali & Brasseur, Guy & Andrade, Maria & Gavidia-Calderón, M & Bouarar, I & Ynoue, Rita. (2016). Prediction of ground-level ozone concentration in São Paulo, Brazil: Deterministic versus statistic models. Atmospheric Environment. 145. 365-375. 10.1016/j.atmosenv.2016.09.061.	Dane pochodzące z 2 stacji rozmieszczonych na terenie Sao Paulo. Pomiary wykonywane co godzinę  Parametry wejściowe dobierane na podstawie algorytmu Forward Selection, zaczynając od parametru o najwyższej korelacji z poziomem ozonu w momencie t + 1 godzina. Parametry są dodawane tak długo, aż spadek Relative Mean Square Error jest wyższy niż 5%.	Cel predykcji: średni dzienny poziom zanieczyszczenia O3, maksymalny dzienny poziom zanieczyszczenia O3.  Weather Research and Forecasting model with Chemistry (dane z dodatkowej jednej stacji),  Sieć neuronowa z jedną warstwą ukrytą z 2 neuronami.	Współczynnik R dla sieci neuronowej przy predykcji średniego dziennego poziomu zanieczyszczenia ozonem R = 0.84 lub 0.75, przy RMSE = 8.12 lub 7.76 w zależności od stacji.  Dla najwyższego dziennego stężenia ozonu: R = 0.64, 0.67, RMSE = 21.20, 13.34.	System WRF/Chem, MATLAB neural network toolbox	Potencjalnie przydatne ze względu na omówioną literaturę

<p>Air Quality - Measurement and Modeling</p> <p>ISBN 978-953-51-2765-9, Print</p> <p>ISBN 978-953-51-2764-2, InTech, December 14, 2016</p> <p>DOI: 10.5772/62563</p>	<p>Wymienione czynniki wpływające na zanieczyszczenie PM10:</p> <ul style="list-style-type: none"> <li>• CO2</li> <li>• SO2</li> <li>• NO</li> <li>• NO2</li> <li>• O3</li> <li>• temperatura</li> <li>• kierunek i prędkość wiatru</li> <li>• opady</li> <li>• promieniowanie słoneczne</li> <li>• godziny ze słońcem</li> <li>• ciśnienie atmosferyczne</li> <li>• wilgotność względna</li> <li>• zachmurzenie</li> <li>• data / godzina</li> </ul>				<p>Nie jest to paper, a książka poświęcona modelowaniu pogody. Zawiera m.in. opis technik uczenia maszynowego i informacje o czynnikach wpływających na poziom zanieczyszczenia.</p>
<p>Giorgio Corani, Air quality prediction in Milan: feed-forward neural networks, pruned neural networks and lazy learning, In Ecological Modelling, Volume 185, Issues 2–4, 2005, Pages 513-529, ISSN 0304-3800, <a href="https://doi.org/10.1016/j.ecolmodel.2005.01.008">https://doi.org/10.1016/j.ecolmodel.2005.01.008</a>.</p>	<p>Dane gromadzone co godzinę w latach 1999-2001.</p> <p>Dodatkowo pomiary PM10 z lat 1999-2002</p> <p>Parametry:</p> <ul style="list-style-type: none"> <li>• poziom O3</li> <li>• promieniowanie słoneczne</li> <li>• kierunek i prędkość wiatru</li> <li>• opady deszczu</li> <li>• ciśnienie atmosferyczne</li> <li>• wilgotność</li> </ul>	<p>Predykcja ma miejsce danego dnia o godzinie 9:00 i ma na celu określenie średniej kroczącej maksymalnych stężeń ozonu w ciągu następnych 8 godzin.</p> <p>Sieć neuronowa Feed-forward</p> <p>Sieć neuronowa typu pruned – ze zredukowaną liczbą połączeń.</p> <p>Lazy Learning</p>	<p>Index of agreement IA &gt; 0.90 dla wszystkich metod.</p>	<p>Matlab</p>	<p>Brakuje szczegółów technicznych odnośnie charakterystyki użytej sieci FF odnośnie liczby warstw ukrytych i liczby neuronów w tych warstwach.</p>
<p>Patricio Perez, Jorge Reyes,</p>	<p>Średnie godzinowe stężenie PM10 mierzone od 1.04 do 31.08 w latach 1998-2000.</p>	<p>Sieci neuronowe z o następujących konfiguracjach (liczba neuronów w na</p>	<p>Różne błędy względne w zależności od zestawu</p>	<p>Nie wskazano</p>	<p>Praca opublikowana</p>

Prediction of maximum of 24-h average of PM10 concentrations 30h in advance in Santiago, Chile, In Atmospheric Environment, Volume 36, Issue 28, 2002, Pages 4555-4561, ISSN 1352-2310, <a href="https://doi.org/10.1016/S1352-2310(02)00419-3">https://doi.org/10.1016/S1352-2310(02)00419-3</a> .  ( <a href="http://www.sciencedirect.com/science/article/pii/S1352231002004193">http://www.sciencedirect.com/science/article/pii/S1352231002004193</a> )	Parametry: <ul style="list-style-type: none"><li>• średnie godzinowe stężenie PM10 o godzinach 0:00, 6:00, 12:00, 18:00 danego dnia,</li><li>• maksymalne stężenie PM10 między godziną 19:00 poprzedniego dnia a 18:00 obecnego,</li><li>• minimalna średnia z 1 godziny wilgotności w okresie między 19:00 poprzedniego dnia a 18:00 obecnego</li><li>• maksymalna temperatura - jak wyżej (19:00 – 18:00),</li><li>• średnia prędkość wiatru – j. w.</li></ul> Dodatkowo – parametry prognozowane na następny dzień: <ul style="list-style-type: none"><li>• minimalna średnia godzinowa wilgotność względna,</li><li>• maksymalna temperatura,</li><li>• różnica między najwyższą a najniższą temperaturą (najważniejszy czynnik wg pracy),</li><li>• średnia prędkość wiatru.</li></ul> Parametr wyjściowy: maksymalne stężenie PM10 w ciągu kolejnych 24 godzin.	warstwę): <ul style="list-style-type: none"><li>• 6 – 1 (Error = 16%)</li><li>• 6 – 4 – 3 -1 (Error 16%)</li></ul> Najniższy błąd obliczony jako względny błąd średniokwadratowy (Relative Mean Square Error ) po zbiorze danych pochodzących z roku 1998 i następujących danych wejściowych: <ul style="list-style-type: none"><li>• stężenie PM10 o 12:00</li><li>• stężenie PM10 o 18:00</li><li>• maksymalna temperatura</li><li>• prognozowana maksymalna temperatura dla następnego dnia</li><li>• różnica między prognozowaną temp. Maksymalną i minimalną następnego dnia</li><li>• średnia prognozowana prędkość wiatru</li></ul>	parametrów wejściowych i danych wykorzystanych do trenowania. Najniższy błąd 16% dla danych z 1998 roku. Najwyższy: 22% dla danych z lat 1998-1999.		w 2002 roku. Ważna ze względów historycznych , ale raczej mało użyteczna.												
Artificial neural network models for prediction of daily fine particulate matter concentrations in Algiers  M. R. Chellali, H. Abderrahim, A. Hamou, A.	Dane zapisywane co godzinę, pochodzące ze stacji meteorologicznej w Aligerze. Zebrane w latach 2002 – 2003.  Parametry (wartości zaobserwowane 24 godziny wcześniej, z wyjątkiem wilgotności – 48 godzin): <ul style="list-style-type: none"><li>• stężenie PM10</li><li>• prędkość wiatru</li><li>• wilgotność względna</li><li>• temperatura</li></ul> Dane były niekompletne. Wybrakowane 5%	Cel predykcji: średnie dzienne stężenie PM10.  MLP, jedna warstwa ukryta. Dla dwóch warstw dokładność predykcji była niesatysfakcjonująca.  Najlepsze wyniki dla sieci 4-15-1. learning rate = 0.05 liczba epok = 23	Wyniki dla najlepszego modelu (4-15-1): <table><tr><td>Learning rate</td><td>0.05</td></tr><tr><td>NMSE</td><td>0.003756</td></tr><tr><td>MAE</td><td>10.79852</td></tr><tr><td>IA</td><td>0.96</td></tr><tr><td>RMSE</td><td>13.78</td></tr><tr><td>R<sup>2</sup></td><td>0.85358</td></tr></table>	Learning rate	0.05	NMSE	0.003756	MAE	10.79852	IA	0.96	RMSE	13.78	R <sup>2</sup>	0.85358	MATLAB 7 neural network toolbox	Dokładnie opisane dane i eksperymenty razem z miarami jakości predykcji. Zawiera tabelę z porównaniem rezultatów z innymi pracami.
Learning rate	0.05																
NMSE	0.003756																
MAE	10.79852																
IA	0.96																
RMSE	13.78																
R <sup>2</sup>	0.85358																

Nebatti, J. Janovec 2016	danych wynikało głównie z przerw w dostępie do energii elektrycznej. Wybrakowane dane nie zostały użyte.				Przydatny artykuł.				
Forecasting hourly PM2.5 in Santiago de Chile with emphasis on night episodes  Patricio Perez, Ernesto Gramsch  2015	Dane gromadzone co godzinę przez 2 stacje monitorujące na terenie Santiago de Chile pochodzące z lat 2010-2011. Dane testowe pochodzą z 2012 r.  Parametry (jeśli nie zaznaczono inaczej, pochodzące ze stacji Cerro Navia): <ul style="list-style-type: none"><li>• średnie stężenie PM2.5 o 18:00,</li><li>• średnie stężenie PM2.5 o 19:00,</li><li>• średnie stężenie PM10 o 18:00,</li><li>• średnie stężenie PM10 o 19:00,</li><li>• średnie stężenie PM2.5 o 18:00 przy stacji Pudahuel,</li><li>• średnie stężenie PM2.5 o 19:00 przy stacji Pudahuel,</li><li>• średnie stężenie PM10 o 18:00 przy stacji Pudahuel,</li><li>• średnie stężenie PM10 o 19:00 przy stacji Pudahuel,</li><li>• prędkość wiatru o 19:00,</li><li>• wilgotność względna o 19:00,</li><li>• amplituda temperatury aktualnego dnia,</li><li>• prognozowana amplituda temperatury kolejnego dnia,</li><li>• prognozowany współczynnik wentylacji PMCA kolejnego dnia.</li></ul>	Cel predykcji: średn godzinowy poziom zanieczyszczenia PM2.5. Predykcja odbywa się dla godzin. 20:00 danego dnia do 16:00 dnia kolejnego dla okresu 1.04.2012 – 31.08.2012.  Dla każdego opóźnienia (+1h, +2h, ..., + 15h) została wytrenowana osobna sieć.  Sieć neuronowa feedforward – 13 zmiennych wejściowych, 1 warstwa ukryta z 8 neuronami, 1 neuron wyjściowy	Błąd względny rzędu 30 - 60%.	Nie wskazano.					
Neural network forecast of daily pollution concentration using optimal meteorological data at synoptic	Dane gromadzone przez 12 stacji monitorujących na terenie Lizbony w latach 2002 – 2006. Dane z roku 2006 zostały wykorzystane do testów, pozostałe - do trenowania.  Parametry (zmierzone dnia poprzedniego): <ul style="list-style-type: none"><li>• średnie dzienne stężenie NO, NO2, CO, PM10 (CO, NO – niewielki wpływ),</li><li>• maksymalne dzienne stężenie PM10,</li></ul>	Cel predykcji: poziom PM10 w chwili t + 1 dzień.  Multiple Linear Regression, Sieć neuronowa z jedną warstwą ukrytą i 2 lub 3 neuronami ukrytymi – skuteczność zbliżona.  Zastosowano 2 warianty modeli dla	Wartości dla najlepszego modelu (RES-7-NN3). <table><tr><td>r</td><td>0.81</td></tr><tr><td>RMSE</td><td>11.69</td></tr></table>	r	0.81	RMSE	11.69	Nie wskazano	
r	0.81								
RMSE	11.69								

and local scales  Ana Russo, Pedro G. Lind , Frank Raischel , Ricardo Trigo, Manuel Mendes  2015	<ul style="list-style-type: none"><li>• stężenie PM10 o 0:00 (najważniejszy czynnik),</li><li>• Circulation Weather Type, określony na podstawie ciśnienia średniego ciśnienia na poziomie morza (SLP), wilgotności względnej, temperatury i wysokości geopotencjalnej dla 1000 hPa (niewielki wpływ),</li><li>• wysokość warstwy granicznej (boundary layer height) o godzinach: 3:00, 9:00, 21:00 (chodzi o najniższą warstwę atmosfery, która ulega dobowym wahaniom temperatury),</li><li>• maksymalna dzienna temperatura,</li><li>• średni kierunek wiatru,</li><li>• średnia prędkość (? , w pracy użyto pojęcia intensity) wiatru (znikomy wpływ),</li><li>• średnia wilgotność względna,</li><li>• radiancja (znikomy wpływ).</li></ul>	modelowania: <ul style="list-style-type: none"><li>• sygnału kompletnego,</li><li>• komponentów rezydualnych.</li></ul> Zbiór zmiennych wejściowych został ograniczony przy użyciu metody Forward Selection.																												
Neural network forecasting of air pollutants hourly concentrations using optimised temporal averages of meteorological variables and pollutant concentrations  Lovro Hrust, Zvezdana Bencetić Klaić, Josip Krizan, Oleg AntoniĆ, Predrag	<p>Dane pochodzą ze stacji monitorującej w Zagrzebiu. Zawierają one wartości średnie z 15 minut. Pomiary zostały rozpoczęte w styczniu 2004 r.</p> <p>Parametry:</p> <ul style="list-style-type: none"><li>• poziomy PM10, CO, NO2, O3.</li><li>• Wilgotność względna,</li><li>• ciśnienie,</li><li>• temperatura,</li><li>• prędkość wiatru.</li><li>• Kierunek wiatru (rozłożony na składową północną i wschodnią).</li></ul> <p>W zależności od typu zanieczyszczenia 2 – 11% danych było wybrakowanych. Zostały one pominięte w eksperymentach numerycznych.</p> <p>Dane wejściowe dla modelu:</p>	<p>Cel predykcji: stężenie CO, PM10 i O3 o zadanej godzinie.</p> <p>Multi Layer Perceptron z 1-2 warstwami ukrytymi. Najlepsze rezultaty dla 1 warstwy ukrytej z 22 neuronami.</p> <p>Dane wejściowe zostały dobrane na podstawie analizy fourierowskiej.</p> <p>Wartości wejściowe stanowią średnie kroczące wyznaczone po różnej liczbie godzin, dla różnych parametrów wejściowych i czynników zanieczyszczających. Okresy zostały wyznaczone na podstawie korelacji między stężeniem prognozowanym a faktycznym.</p>	<p>Wyniki dla sieci neuronowej z 1 warstwą ukrytą i 22 neuronami:</p> <table><tr><td></td><td>NO2</td><td>O3</td><td>CO</td><td>PM10</td></tr><tr><td>MAE</td><td>5.43</td><td>8.49</td><td>0.16</td><td>10.11</td></tr><tr><td>RMSE</td><td>7.95</td><td>11.24</td><td>0.24</td><td>14.70</td></tr><tr><td>IA</td><td>0.96</td><td>0.97</td><td>0.93</td><td>0.89</td></tr><tr><td>R<sup>2</sup></td><td>0.86</td><td>0.90</td><td>0.77</td><td>0.66</td></tr></table>		NO2	O3	CO	PM10	MAE	5.43	8.49	0.16	10.11	RMSE	7.95	11.24	0.24	14.70	IA	0.96	0.97	0.93	0.89	R <sup>2</sup>	0.86	0.90	0.77	0.66	Nie wskazano	
	NO2	O3	CO	PM10																										
MAE	5.43	8.49	0.16	10.11																										
RMSE	7.95	11.24	0.24	14.70																										
IA	0.96	0.97	0.93	0.89																										
R <sup>2</sup>	0.86	0.90	0.77	0.66																										

Hercog  2009	<ul style="list-style-type: none"> <li>wilgotność,</li> <li>prędkość i kierunek wiatru,</li> <li>ciśnienie atmosferyczne,</li> <li>początkowe stężenie czynnika zanieczyszczającego danego dnia,</li> <li>godzina UTC,</li> <li>dzień tygodnia,</li> <li>moment na przestrzeni roku reprezentowanego przez cosinusoidę <math>\cos\left(\frac{2\pi t}{T}\right)</math>, gdzie t to numer dnia w roku, a T liczba dni w roku.</li> </ul>	<p>W niektórych przypadkach (np. prędkość wiatru w kierunku północnym) na wejście sieci neuronowej przekazywane są dwie wartości uśrednione po różnych okresach (1h i 25h dla NO2).</p> <p>Learning rate = 0.1 momentum = 0.3 liczba epok &lt;= 5000</p> <p>Funkcje aktywacji w warstwach:</p> <ul style="list-style-type: none"> <li>ukrytych – logistyczna,</li> <li>wyjściowej – liniowa.</li> </ul>							
--------------------	--	---	--	--	--	--	--	--	--

#### Obserwacje ogólne:

- dominujące podejście w znalezionych pracach – sieć neuronowa z pojedynczą warstwą ukrytą;
- używane miary skuteczności modeli:
  - korelacja,
  - współczynnik Pearson’a r,
  - Relative Mean Square Error,
  - Mean Absolute Error,
  - Index of Agreement;
- techniki radzenia sobie z brakującymi danymi:
  - niewzględnianie wybrakowanych rekordów,
  - uzupełnianie braków uśrednionymi wartościami sąsiednimi.